MACHINE LEARNING II · UNIVERSIDAD EXTERNADO · ENTREGA FINAL

Alerta temprana de deserción

Predecir, al cerrar el primer semestre, qué estudiantes no seguirán al segundo año. Tecnológico de Monterrey.

Miguel Camargo · Camilo Hernández

Profesor: Wilmer Pineda

desercion-tec.streamlit.app

01 · EL ARTÍCULO

Del artículo a nuestra pregunta

VILLAR Y ANDRADE (2024)

- Portugal: 4.424 estudiantes, tres desenlaces
- Datos de ingreso + notas de 1.º y 2.º semestre
- Siete algoritmos: gana el boosting (F1 hasta 0,88)
- SMOTE, Optuna y SHAP

NUESTRA ADAPTACIÓN

- México: 24.251 estudiantes del Tec, dos desenlaces
- Predecimos un semestre antes: solo notas del 1.er semestre
- Nueve modelos en un flujo sin fuga de información
- Modelo desplegado en una aplicación web

02 · ESTRATEGIA DE DATOS

De 143.326 registros a una pregunta precisa

143.326
registros de bachillerato y pregrado, cohortes 2014–2020

24.251
de pregrado, AD19–AD20: las únicas cohortes con notas del 1.er semestre

7,7 %
deserta: ya no está matriculado al cerrar el primer año

80 / 20
desarrollo / prueba sellada, separada por estudiante

Lo que dejamos por fuera, y por qué

- Socioeconómicas: faltan en la mitad de los estudiantes y no distinguen a quien deserta
- Variables que delatan el desenlace: semestre de deserción y actividades del año
- Quienes se retiraron a mitad del primer semestre: al predecir, ya se fueron

03 · FLUJO DE MODELAMIENTO

Un flujo sin fuga de información

Imputar
mediana + marca

→

Escalar
con el pliegue

→

One-hot
categóricas

→

SMOTE
¿sí o no? lo decide la validación

→

Modelo
9 candidatos

Validación cruzada anidada 5 × 3

La interna elige hiperparámetros y umbral; la externa mide con datos que el ajuste no vio.

PR-AUC y umbral con F2

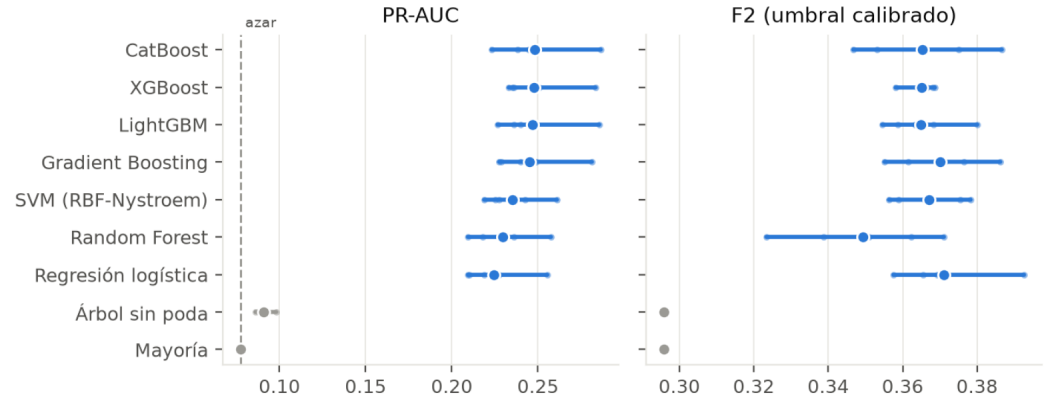
Con 7,7 % de positivos la exactitud engaña. Perder a un desertor cuesta más que una conversación de más.

La fuga del artículo

Aplicar SMOTE antes de separar, como hace el artículo, infla nuestro F1 de 0,12 a 0,95.

04 · ELECCIÓN DEL MODELO

El boosting empata; elegimos LightGBM



Nueve modelos, cinco rondas de validación. Azar: PR-AUC 0,077.

Desempeño

0,247

empata con el boosting (p ≥ 0,68) y supera a la logística (p = 0,035)

Estabilidad

± 0,023

de variación entre las cinco rondas, igual que CatBoost

Costo

0,55 s

por entrenamiento, frente a 16 s de CatBoost

Interpretabilidad

SHAP

exacto para cada estudiante, sin renunciar a desempeño

05 · ANTES DE ABRIR LA PRUEBA

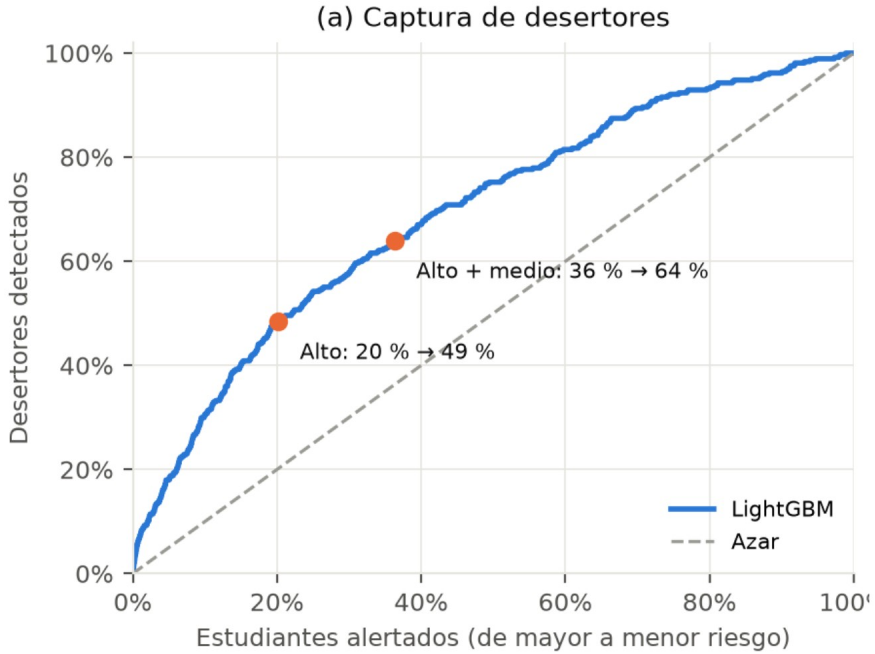
Tres preguntas incómodas, respondidas con datos

Pregunta	Resultado	Decisión
¿La marca “sin dato” de la rúbrica funciona como indicador de cohorte?	PR-AUC 0,2468 con la marca, 0,2467 sin ella y 0,2474 con la cohorte explícita	Se quita: en uso real la rúbrica siempre está
¿Generaliza a una cohorte que no vio?	Entrenar con AD19 y probar en AD20: PR-AUC 0,186 frente a 0,220	Se reporta como limitación
¿Las probabilidades significan lo que dicen?	7,73 % estimado frente a 7,75 % observado; pendiente de calibración 1,04	La app las muestra tal cual

Las tres se respondieron con el conjunto de desarrollo: la prueba siguió sellada.

06 · PRUEBA SELLADA · 4.843 ESTUDIANTES

El 20 % de mayor riesgo concentra la mitad de los desertores



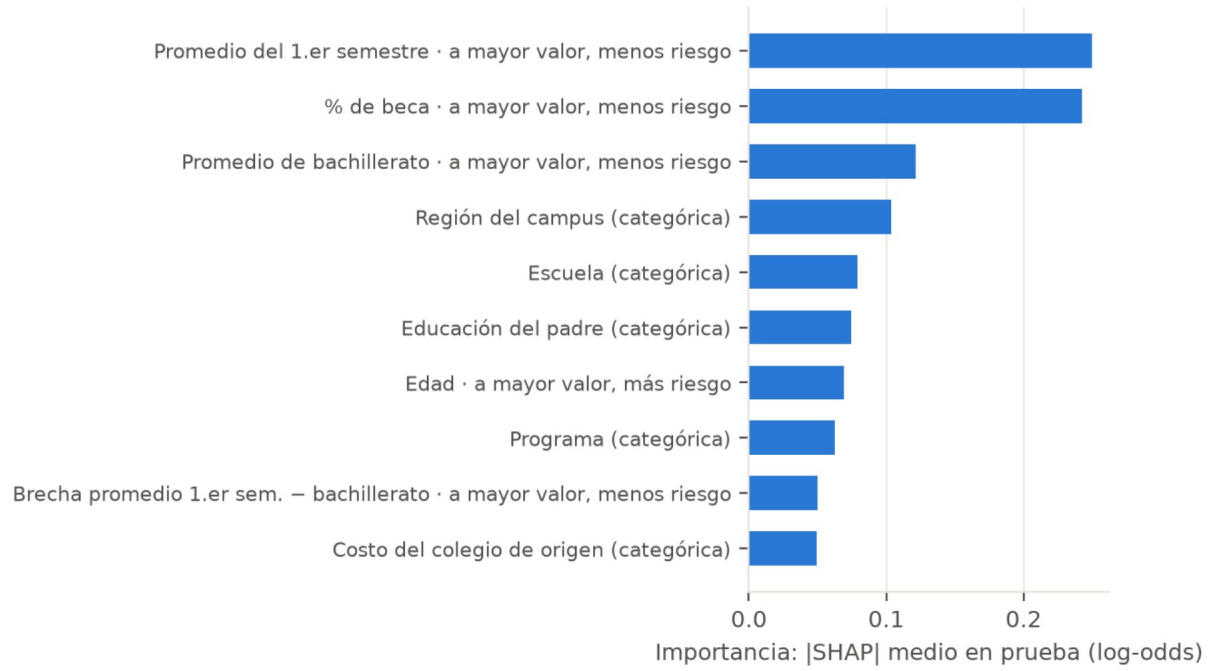
48,5 % de los desertores, alertando solo al 20 %

Nivel	Estudiantes	Deserta	Acción
• Alto	20 %	18,2 %	Contactar ya
• Medio	16 %	7,3 %	Seguimiento
• Bajo	64 %	4,3 %	Habitual

PR-AUC 0,220 (validación: 0,247) · ROC-AUC 0,708 · probabilidades calibradas: 7,8 % estimado frente a 7,6 % real

07 · INTERPRETACIÓN CON SHAP

Qué mira el modelo: arranque académico y apoyo económico



Promedio del 1.er semestre

Mejor promedio, menos riesgo. Es lo que más pesa.

Porcentaje de beca

Más beca, menos riesgo. Pesa casi igual.

Edad

Los estudiantes mayores tienen más riesgo.

Asociaciones del modelo, no causas.

08 · TIPOS DE ERROR

Los errores no cuestan lo mismo

235 de 367

desertores recibieron alerta (64 %). Se escaparon 132.

7,5

alertas por cada desertor encontrado; 5,5 si solo se atiende el nivel alto.

DÓNDE FALLA

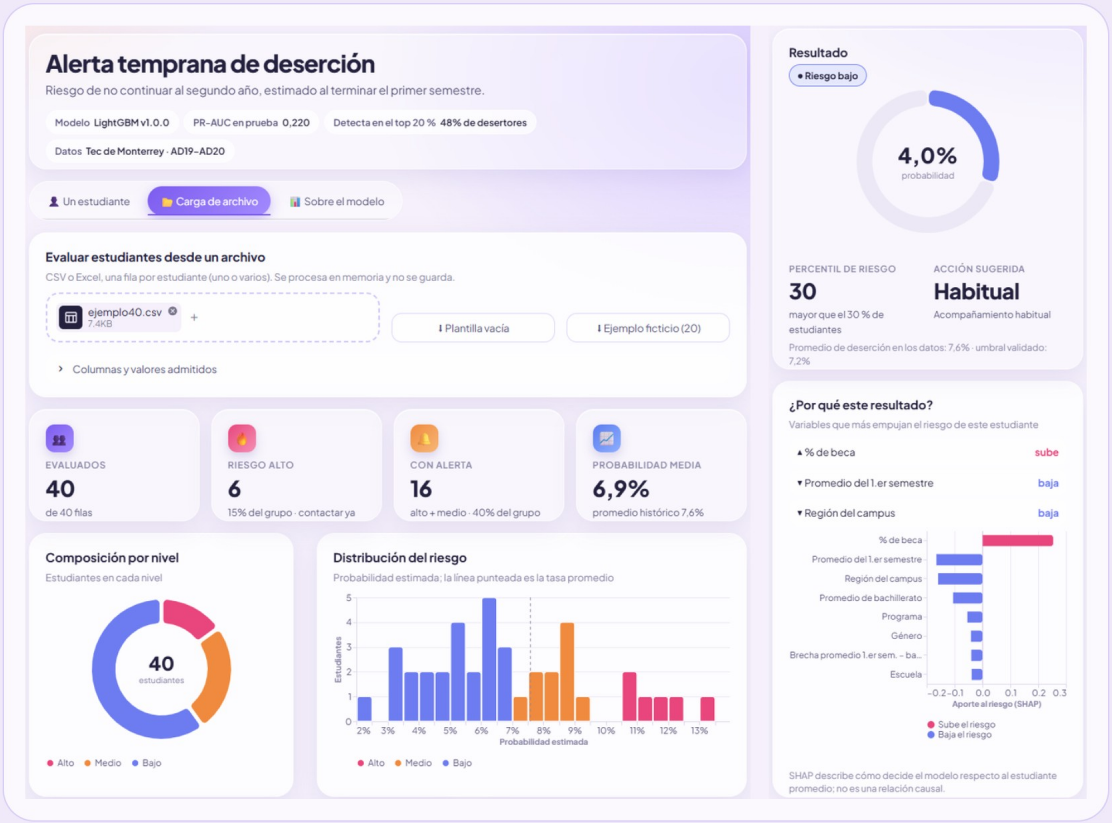
6 de 23

becarios por talento académico que desertan reciben alerta: su beca y su promedio los hacen ver de bajo riesgo.

El modelo no debe ser el único filtro: esos perfiles necesitan el criterio de los consejeros.

09 · DESPLIEGUE

La aplicación, en vivo



desercion-tec.streamlit.app

- Un estudiante (formulario) o muchos (CSV o Excel)
- Probabilidad, nivel, acción y explicación SHAP
- El mismo Pipeline del entrenamiento y un contrato que rechaza entradas fuera de rango
- Predicción de referencia idéntica en local, en Docker y en la nube
- 12 pruebas automáticas en cada actualización

10 · LIMITACIONES Y PROYECCIÓN

Lo que no resuelve y lo que sigue

LIMITACIONES

- Solo dos cohortes, ambas tocadas por la pandemia
- En una cohorte nueva rinde algo menos (PR-AUC cercano a 0,19)
- Señal moderada (ROC-AUC 0,71): prioriza, no diagnostica
- Los becarios que desertan pasan casi inadvertidos

LO QUE SIGUE

- **MLOps:** vigilar entradas y calibración en cada cohorte nueva
- **MLOps:** reentrenar validando con la cohorte más reciente y versionar el contrato
- **Datos:** sumar asistencia y uso de la plataforma para ver a los becarios
- **Deep Learning:** con notas semestre a semestre, modelos secuenciales que aprendan la trayectoria

EN RESUMEN

Ordenar a tiempo para acompañar a tiempo

LightGBM: empata con los mejores y es el más barato

20 % de mayor riesgo: 48,5 % de los desertores

Desplegado, explicable y reproducible

Gracias. ¿Preguntas?

desercion-tec.streamlit.app