Universidad Externado de Colombia

Departamento de Matemáticas

Machine Learning II

Proyecto Integrador — Segunda Entrega

Fase 2: datos, modelamiento y validación

Predicción de deserción estudiantil en el Tecnológico de Monterrey mediante modelado avanzado de Machine Learning

---

Integrantes

Miguel Camargo
Camilo Hernández

Profesor: Wilmer Pineda

Código reproducible:
https://github.com/miguel-camargo611/ML2-desercion-estudiantil

27 de septiembre de 2026

Este informe presenta la segunda fase del proyecto: la consolidación de los datos, la construcción de un flujo de modelamiento sin fuga de información, la reproducción del método de Villar y Andrade (2024) y la evaluación de los modelos. El objetivo es determinar qué modelo predice mejor si un estudiante de pregrado abandonará la universidad durante su primer año, a partir de la información disponible al terminar su primer semestre, para que la institución pueda ofrecerle acompañamiento a tiempo. El código, el análisis exploratorio completo y las instrucciones para reproducir cada resultado están en el repositorio indicado en la portada.

1. Consolidación de los datos

Fuente. Se utilizó el *Student Dropout Dataset* del Tecnológico de Monterrey (Alvarado-Uribe et al., 2022), obtenido mediante solicitud formal al IFE Data Hub. Contiene 143.326 registros de estudiantes de bachillerato y pregrado de siete cohortes de ingreso, de AD14 (agosto de 2014) a AD20 (agosto de 2020). Al tratarse de datos reales latinoamericanos, no fue necesario recurrir a simulación.

Población de estudio y variable objetivo. Villar y Andrade predicen la deserción combinando la información de ingreso con el desempeño de los primeros semestres. En este dataset, el desempeño del primer semestre (promedio, materias reprobadas y materias retiradas) solo se registró para las cohortes AD19 y AD20 (Figura 1), por lo que la población de estudio son los 24.251 estudiantes de pregrado de esas dos cohortes. La predicción se hace al terminar el primer semestre, y la variable objetivo vale 1 si el estudiante ya no está matriculado al cerrar su primer año (`retention` = 0). Se excluyó a los 256 estudiantes que abandonaron *durante* el primer semestre: cuando se hace la predicción ya no están matriculados, y su promedio refleja el abandono en lugar de anticiparlo. El artículo distingue tres desenlaces (graduado, rezagado y desertor), pero este dataset no registra la graduación, así que el problema es de clasificación binaria. Deserta el 7,7 % de los estudiantes, mucho menos que en el artículo (32 %), lo que condiciona la elección de métricas (Sección 4).

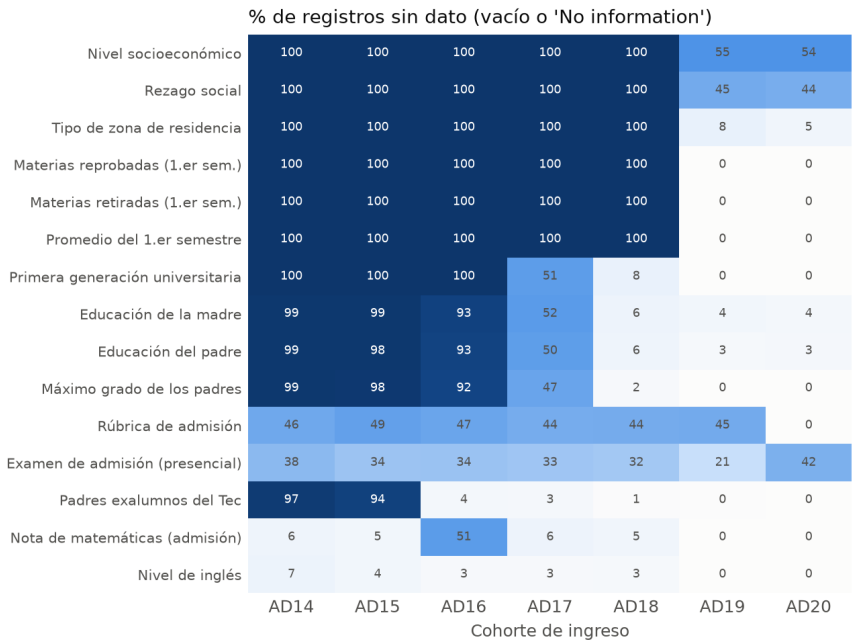


Figura 1: Porcentaje de registros sin dato por variable y cohorte (pregrado, conjunto de desarrollo). Los faltantes dependen de la cohorte: el desempeño del primer semestre solo existe en AD19 y AD20.

Calidad de los datos. El análisis exploratorio (notebook `01_exploracion_datos` del reposi-

Tabla 1: Problemas de calidad encontrados en la población de estudio y decisión adoptada.

Problema	Magnitud	Decisión
Nivel socioeconómico y rezago social sin dato; la deserción es igual con y sin dato	55 % y 44 %	Se excluyen: no son utilizables.
Examen de admisión con dos escalas: presencial (400–1600) y en línea (0–100)	570 estudiantes en línea	Se separa en dos variables antes de modelar.
Puntajes de admisión faltantes; quienes no los tienen desertan más	22–32 %	Imputación con la mediana más una variable que indica el faltante.
% total de apoyo económico, que es la suma de beca y crédito	$\rho = 0{,}96$	Se excluye por redundante.
Actividades extracurriculares medidas *durante* el año	9 variables	Se excluyen: reflejan la permanencia en lugar de anticiparla.
Estudiantes que aparecen más de una vez	6 casos	La partición se hace por estudiante, no por registro.

torio) identificó los problemas de la Tabla 1. Dos variables socioeconómicas, el nivel socioeconómico y el rezago social, **no son utilizables**: faltan para la mitad de los estudiantes porque no se registraron, la tasa de deserción es la misma con y sin dato, y cuando hay dato apenas discriminan (AUC univariada de 0,51). Imputarlas solo añadiría ruido, por lo que se excluyeron. La información familiar disponible y completa, la educación de los padres, sí se conservó.

Variables construidas y selección. Se construyó la *brecha de promedios* (promedio del primer semestre menos promedio de bachillerato), que mide el cambio de rendimiento al llegar a la universidad: quienes bajan más de siete puntos desertan un 18 %, frente a un 5 % de quienes mantienen su nivel. Mejoró el PR-AUC de LightGBM en los cinco pliegues; una segunda variable (materias reprobadas más retiradas) no aportó y se descartó. Luego, con importancia por permutación calculada dentro de cada partición de entrenamiento, se descartaron las cinco candidatas con importancia media nula o negativa (tipo de zona, examen en línea, procedencia, colegio del Tec y primera generación); en particiones nuevas, el PR-AUC fue el mismo con y sin ellas (0,243). El modelo final usa 23 variables: 13 numéricas (promedios de bachillerato y del semestre, brecha, materias reprobadas y retiradas, examen, rúbrica y nota de matemáticas de admisión, nivel de inglés, porcentajes de beca y de crédito, edad y carga académica) y 10 categóricas (educación del padre, de la madre y máximo grado de los padres, padres exalumnos, costo del colegio, tipo de beca, escuela, programa, región y género).

Tabla 2: Tamaño de los conjuntos de datos. El conjunto de prueba se reserva para la entrega final.

Conjunto	Estudiantes	Desertores	Deserción	Variables
Desarrollo (80 %)	19.408	1.505	7,8 %	23
Prueba sellada (20 %)	4.843	367	7,6 %	23

2. Flujo reproducible sin fuga de datos

Hay *fuga de datos* cuando el modelo usa, al entrenar, información que no tendría disponible al momento de predecir. El resultado son métricas optimistas que no se sostienen en la práctica. El flujo se diseñó con tres salvaguardas.

1. Conjunto de prueba sellado. Antes de cualquier análisis se separó el 20 % de los estudiantes como conjunto de prueba, que no se ha usado ni siquiera en el análisis exploratorio y solo se usará en la entrega final. La separación conserva la proporción de desertores y de cohortes, y asigna cada estudiante a un solo lado.

2. Transformaciones dentro de un `Pipeline`. Las transformaciones se encadenaron en este orden: (1) imputación con la mediana más un indicador de faltante; (2) estandarización de las numéricas; (3) codificación *one-hot* de las categóricas (las categorías con menos de 30 registros se agrupan); (4) balanceo opcional con SMOTE, y (5) el clasificador. Cada paso aprende sus parámetros (medianas, medias, desviaciones, categorías y vecinos) solo con el entrenamiento de cada pliegue y los aplica sin recalcularlos a la validación; si el escalamiento usara la media de todos los datos, la validación influiría en el entrenamiento. Se estandariza *antes* de SMOTE porque este interpola entre vecinos según la distancia euclidiana, que sin escalar quedaría dominada por el examen de admisión (hasta 1.600) frente al porcentaje de beca (hasta 1). El escalamiento es indispensable para la regresión logística y la SVM, mientras que los árboles son invariantes a él; por eso CatBoost recibe las variables sin transformar. SMOTE actúa solo al entrenar, de modo que la validación conserva la proporción real de desertores. Las variables construidas son operaciones fila a fila, sin parámetros aprendidos, y pruebas automáticas del repositorio verifican que el imputador y el escalador aprenden solo de las filas de entrenamiento.

3. Validación cruzada anidada. Los datos de desarrollo se dividieron en cinco partes, agrupando por estudiante y conservando la proporción de desertores. En cada una de cinco rondas, cuatro partes se usan para entrenar y la quinta para evaluar. Dentro de las cuatro de entrenamiento, una segunda validación cruzada de tres partes elige los hiperparámetros, y una tercera, también interna, elige el umbral de decisión. Así, la parte usada para evaluar nunca interviene en ninguna elección. Los resultados se reportan como promedio y desviación estándar de las cinco rondas.

Efecto de la fuga en el protocolo del artículo. Villar y Andrade aplican SMOTE a todos los datos antes de separar entrenamiento y validación. Se entrenó el mismo modelo (LightGBM) con ambos protocolos (Tabla 3). Con el protocolo del artículo los resultados parecen excelentes; con el flujo descrito, son modestos. Al aplicar SMOTE antes de separar, los desertores sintéticos de la validación son mezclas de estudiantes que el modelo ya vio al entrenar: reconoce casos casi repetidos en lugar de predecir casos nuevos. Esto sugiere que parte del alto desempeño reportado en el artículo (F1 de 0,83 a 0,88) proviene del protocolo y no del modelo.

Tabla 3: Mismo modelo evaluado con los dos protocolos (cinco rondas). El PR-AUC se explica en la Sección 4.

Protocolo	F1 deserción (umbral 0,5)	PR-AUC
SMOTE antes de separar (artículo)	0,95	0,98
SMOTE solo en entrenamiento (este trabajo)	0,12	0,24

3. Reproducción y adaptación del método

El método del artículo consiste en comparar árboles y ensambles clásicos con cuatro algoritmos de *boosting*, equilibrar las clases con SMOTE, ajustar los hiperparámetros e interpretar el mejor modelo con SHAP. La Tabla 4 resume qué se conservó y qué se modificó.

Tabla 4: Reproducción y adaptación del método de Villar y Andrade (2024).

Elemento	Artículo	Este trabajo
Información	Ingreso + desempeño de los primeros semestres	Ingreso + desempeño del primer semestre (cohortes AD19–AD20)
Variable objetivo	Tres clases: graduado, rezagado y desertor	Binaria: deserta o no en el primer año (el dataset no registra graduación)
Modelos	Árbol, Random Forest, SVM, Gradient Boosting, XGBoost, LightGBM, CatBoost	Los mismos, más regresión logística como referencia; CatBoost con categóricas nativas
Balanceo de clases	SMOTE sobre todos los datos	SMOTE solo sobre el entrenamiento, y como hiperparámetro: la validación decide si se usa
Hiperparámetros	Optuna	`GridSearchCV`, herramienta del curso, dentro de la validación anidada
Métrica principal	F1 ponderado	PR-AUC, *recall* y precisión de la clase deserción
Comparación	Prueba t pareada	Prueba t corregida de Nadeau y Bengio (2003)
Interpretación	SHAP	SHAP, repetido en cada ronda para verificar su estabilidad

Modelos comparados. Se compararon nueve modelos: dos líneas base (un clasificador que asigna a todos la probabilidad promedio de desertar y un árbol de decisión sin poda), la regresión logística como referencia del curso anterior y los seis modelos avanzados del artículo: Random Forest, SVM con kernel RBF, Gradient Boosting, XGBoost, LightGBM y CatBoost. CatBoost recibe las variables categóricas sin codificar, que es su forma de uso prevista, y por eso compensa el desbalance con pesos de clase en lugar de SMOTE. Para manejar el volumen de datos, la SVM usa una aproximación del kernel (Nystroem) y Gradient Boosting, su versión por histogramas.

Ajuste de hiperparámetros. Cada modelo tiene una rejilla con los hiperparámetros que controlan su complejidad y regularización, más la opción de balanceo (Tabla 5). En cada ronda, `GridSearchCV` probó todas las combinaciones (de 4 a 24 por modelo) y eligió la de mayor PR-AUC en la validación interna. La validación **no eligió SMOTE en ninguna de las 30 decisiones** (seis modelos por cinco rondas), y CatBoost tampoco eligió pesos de clase: crear o reponderar desertores no mejora la capacidad de ordenar a los estudiantes por riesgo, y el desbalance se atiende con el umbral de decisión (Sección 4). Se eligieron configuraciones simples: árboles de 2 a 4 niveles o de 4 hojas y regularización fuerte. La curva de validación de LightGBM (Figura 2) muestra por qué: con más hojas por árbol, el PR-AUC de entrenamiento sube de 0,24 a 0,91, mientras que el de validación alcanza su máximo con 8 hojas (0,250) y luego cae, la firma del sobreajuste. En la SVM, γ y C quedaron en el extremo superior de la rejilla, pero ampliar C a 1 ya no mejora (0,232 frente a 0,235). Por su costo, la rejilla de CatBoost se limitó a la profundidad y los pesos de clase.

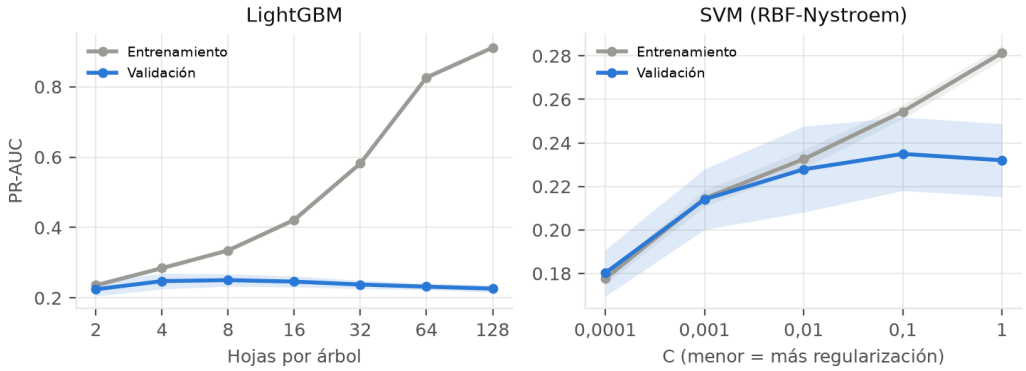


Figura 2: Curvas de validación alrededor de la configuración elegida (media ± desviación estándar de cinco rondas). La brecha creciente entre entrenamiento y validación indica sobreajuste.

Tabla 5: Hiperparámetros explorados y combinación elegida con más frecuencia (entre paréntesis, en cuántas de las cinco rondas se eligió).

Modelo	Valores explorados	Elegido (rondas)
Regresión logística	C: 0,0001, 0,0003, 0,001, 0,003, 0,01, 0,03, 0,1; balanceo: ninguno, SMOTE	0,03, ninguno (2/5)
Random Forest	mín. registros por hoja: 5, 15, 40, 100; variables por división: $\sqrt{p}$, 0,4; balanceo: ninguno, SMOTE	15, 0,4, ninguno (2/5)
SVM (kernel RBF)	γ: 0,001, 0,003, 0,01; C: 0,001, 0,01, 0,1; balanceo: ninguno, SMOTE	0,01, 0,1, ninguno (5/5)
Gradient Boosting	tasa de aprendizaje: 0,02, 0,05; máx. hojas: 4, 8, 16; regularización L2: 0, 1; balanceo: ninguno, SMOTE	0,05, 4, 1, ninguno (4/5)
XGBoost	profundidad máx.: 2, 3, 4; tasa de aprendizaje: 0,02, 0,05; peso mín. por hoja: 1, 10; balanceo: ninguno, SMOTE	2, 0,05, 1, ninguno (4/5)
LightGBM	hojas: 4, 8, 16; tasa de aprendizaje: 0,02, 0,05; mín. registros por hoja: 20, 100; balanceo: ninguno, SMOTE	4, 0,02, 100, ninguno (2/5)
CatBoost	profundidad: 4, 6; pesos de clase: ninguno, balanceados	4, ninguno (4/5)

Otros elementos del artículo. (i) *SMOTE frente a ADASYN.* Como en el artículo, con un árbol de control SMOTE superó levemente a ADASYN (F1 de la clase deserción de 0,154 frente a 0,148), pero ninguno superó al árbol sin balanceo (0,162). (ii) *Isolation Forest.* El artículo lo usa para ver si los desertores son casos atípicos; se repitió su resultado negativo (ROC-AUC de 0,55, donde 0,5 equivale al azar). (iii) *Regresión logística.* El artículo la descartó por multicolinealidad. Aquí se reprodujo el problema (VIF de 10^7), causado por el % total de apoyo, que es la suma exacta de beca y crédito; al excluirlo, el VIF de la beca baja a 1,3 y el modelo se conservó como referencia. La única colinealidad restante es deliberada: la brecha es la resta de dos variables del modelo, útil para los árboles (que dividen por una variable a la vez y no pueden calcularla) e innecesaria para la regresión logística, cuya regularización L2 mantiene estables los coeficientes.

Por qué no se usaron modelos de densidad ni de clustering. La Primera entrega los dejó para fases posteriores, siguiendo el calendario del curso, pero se decidió no incluirlos. La guía pide comparar modelos "según el artículo", y Villar y Andrade solo usan un método no supervisado, Isolation Forest, que sí se reprodujo. Su resultado refuta la hipótesis que justificaría un enfoque de densidad: los desertores no ocupan regiones atípicas o poco densas. Además, el problema es supervisado: el clustering agrupa sin usar la etiqueta, sin garantía de separar a quienes desertan, y un clasificador generativo, como una mezcla gaussiana por clase, supone variables continuas y aproximadamente normales, mientras que aquí 10 de las 23 son categóricas y las numéricas son asimétricas y tienen faltantes.

4. Validación, métricas e interpretación preliminar

Métricas. Con solo 7,8 % de desertores, la exactitud y el F1 ponderado que usa el artículo son engañosos: un modelo que declara a todos como no desertores obtiene un F1 ponderado de 0,89 sin detectar a ningún desertor. Por eso se usaron tres métricas centradas en la clase deserción:

- **PR-AUC** (área bajo la curva precisión–*recall*): mide qué tan bien el modelo ordena a los estudiantes de mayor a menor riesgo, sin depender de un umbral. Un modelo al azar obtiene la proporción de desertores (0,078) y uno perfecto obtiene 1. Se usó para elegir los hiperparámetros y comparar los modelos.
- ***Recall*:** proporción de desertores que el modelo detecta.
- **Precisión:** proporción de alertas que corresponden a desertores reales.

El *umbral de decisión* es la probabilidad a partir de la cual el modelo emite una alerta. Se eligió dentro de los datos de entrenamiento para maximizar la métrica F2, que da al *recall* el doble de

peso que a la precisión. Así se formaliza la prioridad definida en la Primera entrega: no detectar a un desertor cuesta más que acompañar a un estudiante que no estaba en riesgo.

Resultados. La Tabla 6 y la Figura 3 resumen el desempeño. Todos los modelos avanzados superan con claridad a las líneas base: el árbol sin poda obtiene un PR-AUC casi igual al azar (0,091 frente a 0,078) porque memoriza los datos de entrenamiento. Las líneas base aparecen con *recall* de 1,00 porque asignan a todos el mismo puntaje (o solo dos valores) y el umbral que maximiza F2 termina alertando a todos; por eso se comparan por PR-AUC. Entre los modelos avanzados, la familia de *boosting* encabeza y está prácticamente empatada: CatBoost (0,248), XGBoost (0,248), LightGBM (0,247) y Gradient Boosting (0,245). Les siguen la SVM (0,235), Random Forest (0,230) y la regresión logística (0,224). La ROC-AUC, cercana a 0,72 en todos los casos, confirma lo que anticipó el análisis exploratorio: la señal es débil y está repartida entre muchas variables.

Tabla 6: Resultados de la validación cruzada anidada: PR-AUC y ROC-AUC (promedio ± desviación estándar de las cinco rondas); *recall*, precisión y proporción de estudiantes alertados con el umbral elegido. En negrita, el mejor PR-AUC.

Modelo	PR-AUC	ROC-AUC	Recall	Precisión	Alertas
Mayoría	0,078 ±0,000	0,500 ±0,000	1,00	0,08	1,00
Árbol sin poda	0,091 ±0,005	0,546 ±0,011	1,00	0,08	1,00
Regresión logística	0,224 ±0,019	0,715 ±0,010	0,64	0,14	0,36
Random Forest	0,230 ±0,018	0,697 ±0,012	0,58	0,14	0,33
SVM (kernel RBF)	0,235 ±0,017	0,716 ±0,007	0,63	0,14	0,36
Gradient Boosting	0,245 ±0,022	0,716 ±0,007	0,68	0,13	0,40
XGBoost	0,248 ±0,021	0,717 ±0,009	0,60	0,14	0,33
LightGBM	0,247 ±0,023	0,716 ±0,005	0,67	0,13	0,40
CatBoost	**0,248 ±0,023**	0,711 ±0,009	0,66	0,13	0,39

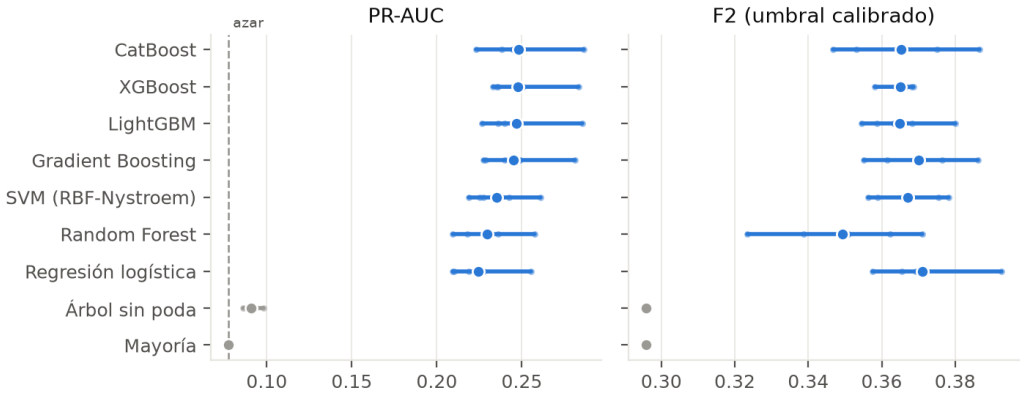


Figura 3: PR-AUC y F2 de cada modelo en las cinco rondas (puntos pequeños) y su promedio (punto grande). La línea punteada es el PR-AUC de un modelo al azar.

¿Son reales las diferencias? Se usó la prueba t corregida de Nadeau y Bengio (2003), que, a diferencia de la prueba t pareada del artículo, tiene en cuenta que las cinco rondas comparten buena parte de los datos de entrenamiento. CatBoost no se distingue de XGBoost, LightGBM ni Gradient Boosting ($p \geq 0{,}44$), ni con claridad de la SVM ($p = 0{,}09$) o de Random Forest ($p = 0{,}13$); sí supera a la regresión logística ($p = 0{,}026$) y a las líneas base ($p < 0{,}001$). Con la prueba t pareada, las diferencias con la SVM y Random Forest parecerían significativas ($p = 0{,}030$ y $0{,}047$), lo que muestra por qué la corrección importa. En síntesis, el *boosting* mejora de forma real, pero pequeña, a un modelo lineal bien regularizado.

Costo computacional. Con desempeños empatados, el costo es un criterio legítimo de desem-

pate (Tabla 7). CatBoost, primero por un margen mínimo, es el más caro de ajustar: 16 segundos por modelo y 30 minutos de búsqueda con solo cuatro combinaciones, frente a 0,5 segundos y 5,5 minutos con 24 combinaciones de LightGBM, que obtiene el mismo PR-AUC. Random Forest ocupa 27 MB, frente a menos de 0,4 MB de los modelos de *boosting*. Predecir es barato para todos: menos de 16 milisegundos por cada mil estudiantes.

Tabla 7: Costo computacional (procesador de 12 hilos). Búsqueda: validación cruzada anidada completa. Ajuste y predicción: modelo final con los hiperparámetros elegidos, sobre los 19.408 estudiantes de desarrollo (mediana de tres repeticiones).

Modelo	PR-AUC	Combinaciones	Búsqueda (min)	Ajuste (s)	Predicción (ms/1.000)	Tamaño (MB)
Mayoría	0,078	1	0,4	0,20	2,9	0,01
Árbol sin poda	0,091	1	0,3	0,44	2,9	0,32
Regresión logística	0,224	14	1,5	0,30	3,4	0,01
Random Forest	0,230	16	24,9	4,57	14,9	26,90
SVM (kernel RBF)	0,235	18	3,9	2,35	15,7	2,31
Gradient Boosting	0,245	24	6,0	1,23	9,2	0,23
XGBoost	0,248	24	11,8	1,02	5,6	0,37
LightGBM	0,247	24	5,5	0,55	7,1	0,25
CatBoost	0,248	4	29,7	15,96	5,4	0,21

Lectura de los resultados. Con el umbral F2, CatBoost detecta el 66 % de los desertores, pero alerta al 39 % de los estudiantes y solo 13 de cada 100 alertas corresponden a desertores reales. Una lectura más práctica supone que la universidad solo puede acompañar a una parte de los estudiantes: si atiende al 20 % con mayor riesgo, detecta al 46 % de los desertores, 2,3 veces lo que lograría eligiendo al azar; si atiende al 10 %, detecta al 32 %, y una de cada cuatro alertas es correcta.

Variables más influyentes. SHAP asigna a cada variable su contribución a la predicción de cada estudiante. Se aplicó a CatBoost en las cinco rondas para verificar la estabilidad de las conclusiones. El promedio del primer semestre es la variable más influyente en cuatro de las cinco rondas, y el porcentaje de beca, en la restante; les siguen el promedio de bachillerato, la rúbrica de admisión, el programa y la nota de matemáticas. La Figura 4 muestra la dirección de los efectos: un promedio del semestre bajo eleva mucho el riesgo, mientras que uno alto lo reduce poco; las becas altas y un mejor desempeño previo se asocian con menor riesgo; la edad mayor y una caída del rendimiento respecto al bachillerato (brecha negativa) lo aumentan. Se reproduce así el hallazgo central del artículo: el desempeño académico temprano es el mejor predictor de la deserción. Estas relaciones son predictivas, no causales.

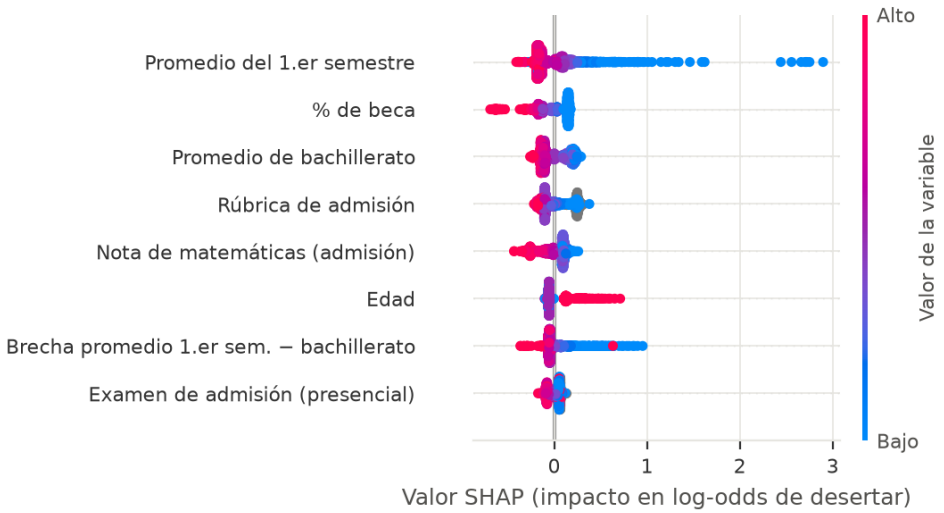


Figura 4: Valores SHAP de CatBoost para las variables numéricas más influyentes (2.000 estudiantes de validación de la última ronda). Cada punto es un estudiante; los valores positivos aumentan el riesgo estimado de desertar.

Errores e implicaciones. El modelo casi no detecta a los desertores con beca por talento académico (6 de cada 100): su riesgo estimado es bajo y las razones por las que se van no aparecen en los datos. En cambio, emite alertas para el 59 % de los estudiantes sin beca que no desertan. Por eso, el modelo debe usarse para priorizar el acompañamiento y no para etiquetar a los estudiantes, ya que varias de sus señales reflejan condiciones económicas.

Pasos para la entrega final. Evaluar una sola vez el modelo elegido, con su umbral ya fijado, en el conjunto de prueba sellado; profundizar la interpretación con gráficos de dependencia, y desplegar el modelo en una aplicación de Streamlit que explique cada predicción.

Declaración de uso de IA generativa. Se utilizó un asistente de inteligencia artificial (Claude, de Anthropic) como apoyo en la escritura del código y la revisión del texto. Los autores verificaron los resultados y pueden sustentar cada decisión técnica.

Referencias

[1] Villar, A. & Robledo Velini de Andrade, C. (2024). Supervised machine learning algorithms for predicting student dropout and academic success: a comparative study. *Discover Artificial Intelligence*, 4:2. https://doi.org/10.1007/s44163-023-00079-z

[2] Alvarado-Uribe, J., Mejía-Almada, P., Masetto Herrera, A. L., Molontay, R., Hilliger, I., Hegde, V., Montemayor Gallegos, J. E., Ramírez Díaz, R. A., & Ceballos, H. G. (2022). Student Dataset from Tecnologico de Monterrey in Mexico to Predict Dropout in Higher Education. *Data*, 7(9), 119. https://doi.org/10.3390/data7090119

[3] Martins, M. V., Tolledo, D., Machado, J., Baptista, L. M., & Realinho, V. (2021). Early prediction of student's performance in higher education: a case study. En *Trends and Applications in Information Systems and Technologies*, vol. 9 (pp. 166–175). Springer.

[4] Nadeau, C. & Bengio, Y. (2003). Inference for the generalization error. *Machine Learning*, 52(3), 239–281.

[5] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: synthetic minority oversampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357.

[6] Lundberg, S. M. & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.