Universidad Externado de Colombia

Departamento de Matemáticas

Machine Learning II

Proyecto Integrador — Segunda Entrega

Fase 2: datos, modelamiento y validación

Predicción de deserción estudiantil en el Tecnológico de Monterrey mediante modelado avanzado de Machine Learning

---

Integrantes

Miguel Camargo
Camilo Hernández

Profesor: Wilmer Pineda

Código reproducible:
https://github.com/miguel-camargo611/ML2-desercion-estudiantil

27 de septiembre de 2026

En la Primera entrega planteamos reproducir el método de Villar y Andrade (2024) —SMOTE, comparación de árboles y ensambles contra la familia de *boosting*, ajuste de hiperparámetros y SHAP— sobre datos latinoamericanos. Esta entrega consolida los datos, construye el flujo sin fuga, compara diez modelos con validación cruzada anidada y ofrece una primera lectura del mejor. El código, con pruebas automáticas, está en el repositorio de la portada, y cada cifra del informe se regenera con `python -m desercion.cli all`.

1. Consolidación de los datos

Fuente definitiva: se activó el Plan A. El IFE Data Hub del Tecnológico de Monterrey aprobó nuestra solicitud y entregó el *Student Dropout Dataset* completo (Alvarado-Uribe et al., 2022): 143.326 registros de 121.584 estudiantes, cohortes AD14–AD20, 50 variables. Al ser real, latinoamericano y superar los 5.000 registros, no hizo falta el Plan B (España) ni simular datos.

Población y objetivo. El dataset mezcla bachillerato y pregrado; conservamos solo **pregrado** (77.517 registros), que es la población del artículo. La variable `retention` indica si el estudiante sigue matriculado al cabo del primer año; definimos `desercion` = 1−`retention`, con una prevalencia de 8,8 % (Figura 1a). Esto obliga a corregir el planteamiento de la Primera entrega: el dataset *no* registra la graduación, así que no existe un análogo de las clases *Graduate* y *Enrolled*. El problema principal es, por tanto, binario, y la estructura de tres clases del artículo se reproduce como experimento secundario usando `dropout.semester` (retenido / deserción en el primer semestre / deserción en el segundo; Figura 1b). El desbalance es mucho mayor que en el artículo (8,8 % frente a 32 % de *Dropout*), lo que condiciona la elección de métricas (Sección 4).

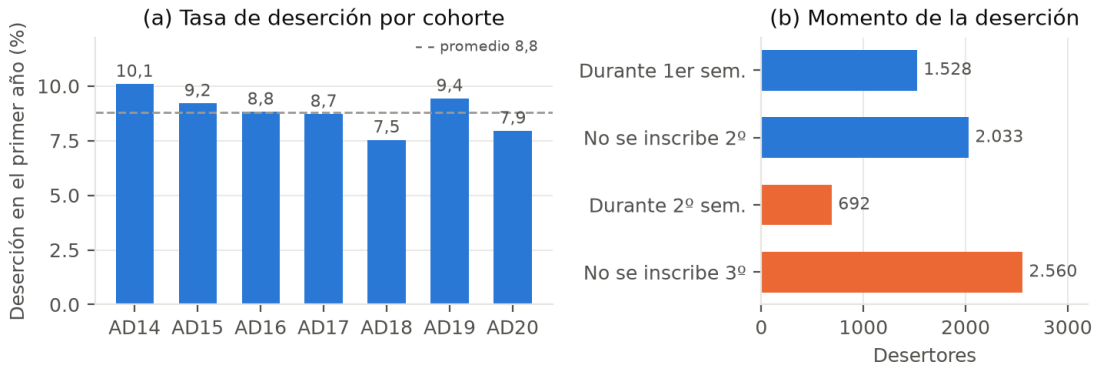


Figura 1: (a) La deserción en el primer año oscila entre 7,5 % y 10,1 % según la cohorte, sin tendencia clara. (b) El 52 % de los desertores se va en el primer semestre o no se inscribe al segundo; el resto lo hace durante el segundo semestre o antes del tercero.

Calidad. No hay celdas vacías sin explicación, pero la ausencia es abundante y de dos tipos (Figura 2). La *estructural* se da cuando la variable no existe para ese estudiante: el desempeño del primer periodo solo se registró en AD19–AD20, y el puntaje de admisión es "Does not apply" para el 32,6 % de los estudiantes, admitidos por otras vías. La *informativa* aparece en las variables socioeconómicas, con "No information" en el 45–86 % de los casos; la conservamos como categoría propia porque no es aleatoria. Detectamos además tres problemas: (i) 21.626 estudiantes de pregrado también aparecen como alumnos de bachillerato y 80 se repiten dentro de pregrado, lo que obliga a particionar *por estudiante*; (ii) la cohorte AD15 no registra ningún caso de "no se inscribe al segundo semestre", una irregularidad que desaconseja usar el momento exacto de la deserción como objetivo; (iii) las actividades co-curriculares (deportes, cultura, programa LIFE) tienen el valor "No information" con un 74,5 % de desertores, frente al 8,8 % general: el dato falta *porque* el estudiante se fue, lo cual es fuga.

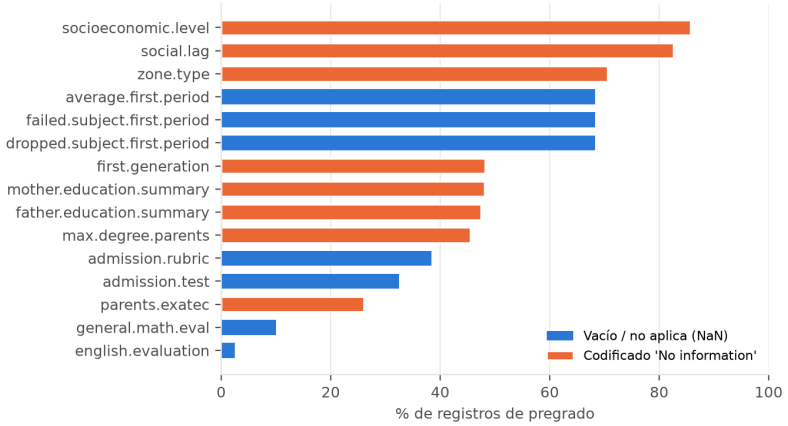


Figura 2: Porcentaje de ausencia por variable usada (pregrado). En azul, la ausencia estructural (la variable no aplica o no se midió), que se imputa con la mediana y un indicador. En naranja, "No information", que se conserva como categoría.

Transformaciones. Todas se aplican fila por fila, sin mirar el objetivo: las variables mixtas (`admission.test`, `general.math.eval`) pasan a numéricas y los códigos de ausencia, incluidos los ceros que significan "sin dato", se marcan como faltantes. Se excluyen 19 variables (lista y motivo en `reports/tables/variables_excluidas.csv`): el objetivo y su derivada `dropout.semester`, que solo es positiva si el estudiante desertó; el identificador y el nivel, constante tras el filtro; la cohorte (`generation`), porque una cohorte futura no existiría en entrenamiento; cuatro variables redundantes; el colegio de origen (6.534 niveles, cuya información resumen `school.cost` y `tec.no.tec`), y las nueve actividades co-curriculares por la fuga descrita.

Dos escenarios de predicción. Para reproducir el paso de Martins et al. (2021) a Villar y Andrade (2024) definimos dos momentos de decisión (Tabla 1). El **escenario A** (*al ingreso*) usa las 28 variables disponibles al matricularse, en todas las cohortes. El **escenario B** (*fin del primer periodo*) añade el promedio y las materias reprobadas y retiradas del primer periodo, disponibles solo en AD19–AD20. En B excluimos a quienes desertaron *durante* el primer semestre: al momento de la predicción ya no están matriculados y su promedio (54,9 frente a 89,7 de los retenidos) refleja el abandono en lugar de anticiparlo. Es una fuga temporal que el artículo no discute y que habría inflado los resultados.

Tabla 1: Conjuntos de trabajo. El 20 % de los estudiantes queda en un conjunto de prueba sellado hasta la Entrega final.

Escenario	Cohortes	Variables	Desarrollo	Prueba (sellada)	Deserción
A — al ingreso	AD14–AD20	28	62.014	15.503	8,8 %
B — fin del 1.er periodo	AD19–AD20	31	19.408	4.843	7,8 %

2. Flujo reproducible sin fuga de datos

Partición. Antes de cualquier análisis de modelos separamos el 20 % de los estudiantes como conjunto de prueba, con `StratifiedGroupKFold`: se estratifica por cohorte y objetivo y se agrupa por `student.id`, de modo que ningún estudiante queda a ambos lados. Ese conjunto no se ha usado y se reserva para la evaluación final.

Pipeline. Cada modelo es un único `Pipeline` de `imbalanced-learn` con cinco etapas en este orden: (1) imputación numérica con la mediana más un indicador de faltante, (2) estandarización, (3) *one-hot* de las categóricas, con agrupación de las categorías de menos de 30 registros,

(4) SMOTE y (5) clasificador. El orden previene la fuga porque cada etapa aprende sus parámetros —medianas, medias y desviaciones, categorías, vecinos de SMOTE— con `fit` sobre el entrenamiento de cada pliegue y en validación solo aplica `transform`. SMOTE va después del escalamiento porque interpola con distancias euclidianas, y solo se ejecuta al ajustar, nunca al predecir: la validación conserva la distribución real de clases. En CatBoost nativo, las etapas 2 a 4 se sustituyen por categóricas nativas y pesos de clase. Pruebas automáticas verifican estas propiedades.

Validación anidada y umbral. El desempeño se estima con validación cruzada anidada: 5 pliegues externos (`StratifiedGroupKFold`) y, dentro de cada entrenamiento externo, `GridSearchCV` con 3 pliegues internos para elegir los hiperparámetros por PR-AUC. El umbral de decisión también se fija sin tocar la validación: con los hiperparámetros elegidos se generan predicciones fuera de pliegue dentro del entrenamiento externo (3 pliegues) y se toma el umbral que maximiza F2. El pliegue externo solo se usa para medir. La semilla (42) y el esquema de validación viven en `configs/config.yaml`.

Por qué importa: el protocolo del artículo infla los resultados. Villar y Andrade aplican SMOTE a todo el conjunto como "primer paso" y solo después validan. Reprodujimos ambos protocolos con el mismo LightGBM y los mismos hiperparámetros sobre el escenario A (Figura 3). En la versión de tres clases, el F1 de las clases de deserción pasa de 0,02 (SMOTE dentro del pliegue) a 0,76 (SMOTE antes de partir), un valor cercano al 0,83–0,88 que reporta el artículo; en la versión binaria, el F1 de la deserción sube de 0,03 a 0,94. La inflación tiene dos causas: los puntos sintéticos de validación son interpolaciones de vecinos que están en entrenamiento, y la validación queda balanceada artificialmente. El resultado sugiere que buena parte del desempeño publicado se debe al protocolo y no al modelo.

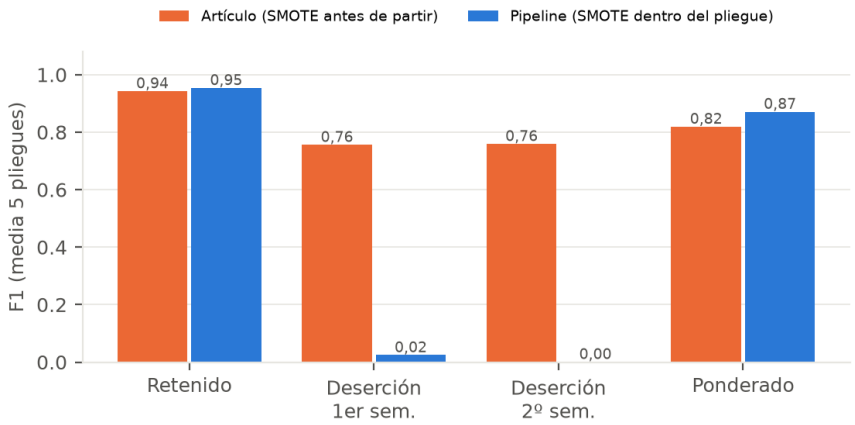


Figura 3: F1 por clase (umbral 0,5) del mismo LightGBM bajo dos protocolos, formulación de tres clases del escenario A. Sobremuestrear antes de partir produce cifras del orden de las del artículo; dentro del pliegue, las clases minoritarias son casi indistinguibles.

3. Reproducción y adaptación del método

La Tabla 2 resume qué se conservó del artículo y qué se modificó. El propósito se mantiene —un sistema de alerta temprana que compare ensambles de *boosting* con métodos clásicos bajo desbalance y explique sus predicciones—, y cada cambio responde a los datos, a las técnicas del curso o a la corrección de la fuga descrita.

Tabla 2: Reproducción y adaptación del método de Villar y Andrade (2024).

Elemento	Artículo	Esta entrega (y motivo)
Objetivo	3 clases (*Graduate*, *Enrolled*, *Dropout*)	Binario; las 3 clases, como experimento (el dataset no registra graduación)
Momento	Matrícula + dos semestres	Escenarios A (ingreso) y B (primer periodo)
Modelos	DT, RF, SVM, GB, XGBoost, CatBoost, LightGBM	Los mismos, más regresión logística como referencia; GB con `HistGradientBoosting` y SVM RBF con aproximación de Nystroem (escalan a 62.000 registros)
Categóricas	Codificación numérica	One-hot y, como adaptación, CatBoost con categóricas nativas y pesos de clase ("CatBoost nativo")
Desbalance	SMOTE sobre todo el conjunto	SMOTE dentro del `Pipeline`; se contrasta con ADASYN, pesos de clase y sin balanceo
Hiperparámetros	Optuna, 20 ensayos, F1 ponderado	`GridSearchCV` anidado con PR-AUC (herramienta del curso)
Comparación	t pareada (plataforma STAC)	t pareada, Wilcoxon y t corregida de Nadeau–Bengio
Anomalías	Isolation Forest (contaminación *auto* y 0,5)	Idéntico, ajustado solo con entrenamiento
Interpretación	SHAP sobre CatBoost y LightGBM	SHAP en cada pliegue externo, para medir estabilidad

Comparación de modelos. La Tabla 3 reporta la validación cruzada anidada. Todos los modelos avanzados superan con amplitud a las líneas base: su PR-AUC es de 1,8 a 2,3 veces la prevalencia en A y de 2,3 a 3,0 veces en B. El árbol sin poda queda casi en el azar (PR-AUC de 0,095 y 0,086), y su umbral F2 óptimo termina alertando a todos, lo que ilustra la alta varianza que los ensambles corrigen. Entre los modelos avanzados las diferencias son pequeñas. En A gana CatBoost con categóricas nativas (0,199), seguido de la regresión logística (0,192) y la SVM (0,191); los ensambles con SMOTE quedan detrás (0,182–0,187). En B gana LightGBM (0,233), con CatBoost nativo, CatBoost y Gradient Boosting a menos de 0,006, y los modelos lineales en 0,216. Random Forest es el ensamble más débil en ambos escenarios. La Figura 4 muestra que las curvas de los mejores modelos prácticamente se superponen.

Tabla 3: Validación cruzada anidada (5 pliegues externos, 3 internos): media y desviación estándar entre pliegues externos. F2 y *recall* con el umbral calibrado dentro de cada entrenamiento. En negrita, el mejor modelo avanzado por columna. †Sin SMOTE: pesos de clase y categóricas nativas.

	Escenario A				Escenario B			
Modelo	PR-AUC	ROC-AUC	F2	Recall	PR-AUC	ROC-AUC	F2	Recall
Mayoría	0,088 ±0,000	0,500	0,325 ±0,000	1,000	0,078 ±0,000	0,500	0,296 ±0,000	1,000
Árbol sin poda	0,095 ±0,003	0,530	0,325 ±0,000	1,000	0,086 ±0,001	0,534	0,296 ±0,000	1,000
Regresión logística	0,192 ±0,011	0,685	0,376 ±0,009	0,688	0,216 ±0,017	0,705	0,366 ±0,016	0,648
Random Forest	0,162 ±0,004	0,667	0,367 ±0,007	0,733	0,179 ±0,006	0,684	0,347 ±0,013	0,622
SVM (RBF)	0,191 ±0,012	0,684	0,378 ±0,008	0,717	0,216 ±0,021	0,704	**0,368 ±0,014**	0,668
Gradient Boosting	0,185 ±0,010	0,677	0,373 ±0,008	0,772	0,228 ±0,029	0,699	0,353 ±0,005	0,748
XGBoost	0,182 ±0,010	0,672	0,368 ±0,009	0,792	0,224 ±0,026	0,696	0,353 ±0,012	0,719
LightGBM	0,187 ±0,010	0,678	0,375 ±0,009	0,764	**0,233 ±0,028**	0,701	0,360 ±0,010	0,730
CatBoost	0,186 ±0,009	0,677	0,372 ±0,009	0,745	0,228 ±0,024	0,704	0,364 ±0,012	0,674
CatBoost nativo†	**0,199 ±0,010**	**0,694**	**0,384 ±0,007**	0,700	0,230 ±0,023	**0,709**	0,364 ±0,013	0,682

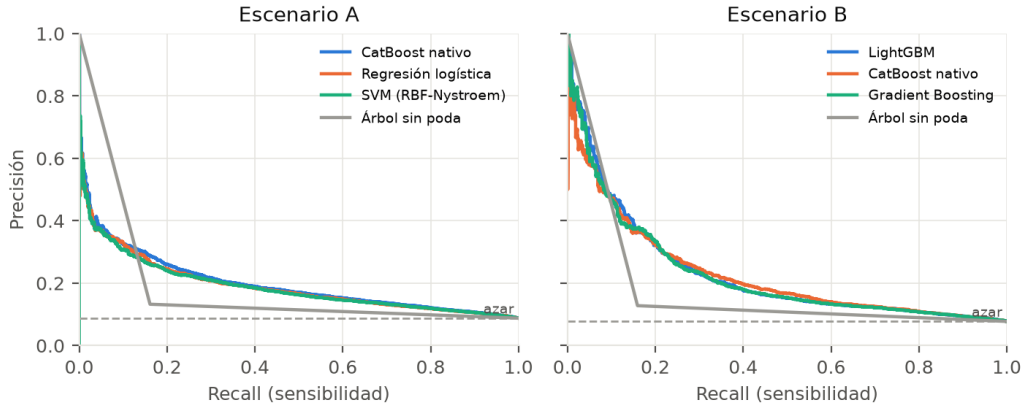


Figura 4: Curvas precisión–*recall* fuera de pliegue de los tres mejores modelos y del árbol sin poda. La línea discontinua es la prevalencia (clasificador al azar). La precisión cae rápido: el riesgo alto se concentra en un grupo pequeño y el resto de los desertores se parece a los retenidos.

Balanceo: SMOTE no aporta aquí. Con el árbol de control del artículo, SMOTE supera levemente a ADASYN (F1 de deserción de 0,146 frente a 0,142), el mismo orden que reportan los autores, pero ninguno mejora al árbol sin balanceo (0,150). Con LightGBM, SMOTE *empeora* el PR-AUC en A (0,186 frente a 0,201 sin balanceo) y es neutro en B (0,237 frente a 0,236); los pesos de clase igualan a no balancear. El balanceo desplaza las probabilidades, pero no mejora la capacidad de ordenar a los estudiantes por riesgo, y ese desplazamiento ya lo absorbe la calibración del umbral. Por eso el mejor modelo de A es justamente el que prescinde de SMOTE, y la ablación y la interpretación (Sección 4) se hacen con modelos sin SMOTE.

Otras piezas del artículo. (i) *Isolation Forest* replica la conclusión negativa de los autores con más contundencia: su puntaje de anomalía tiene un ROC-AUC de 0,54, y con contaminación 0,5 marca como anómalos al 55 % de los desertores y al 49 % de los retenidos. (ii) El VIF también supera 10^7, como en el artículo, pero la causa es una identidad contable (`total.scholarship.loan` = beca + crédito). Eso justifica quitar una variable o regularizar, no descartar la regresión logística: con penalización L2 fuerte (C entre 0,0003 y 0,01) esta resulta competitiva. (iii) La formulación de tres clases no se sostiene sin la fuga: con información de admisión, el F1 de "deserción en el primer semestre" y "en el segundo" no pasa de 0,09 con ningún modelo, es decir, el momento de la deserción no es predecible al ingreso.

Ajuste de hiperparámetros. En la primera corrida, las rejillas de LightGBM, la regresión logística, la SVM y Random Forest eligieron el extremo más simple o más regularizado en todos los pliegues, lo que indicaba un óptimo fuera de la rejilla. Las ampliamos y re-entrenamos esos modelos. Ahora LightGBM (8–31 hojas), Random Forest en A y la regresión logística en A eligen puntos interiores; la SVM y la regresión logística en B siguen prefiriendo la máxima regularización, lo que se explorará en la Entrega final. La curva de validación (Figura 5) confirma el diagnóstico: el PR-AUC de validación se estabiliza entre 8 y 31 hojas, mientras el de entrenamiento sigue subiendo hasta 0,86–1,00, un sobreajuste claro.

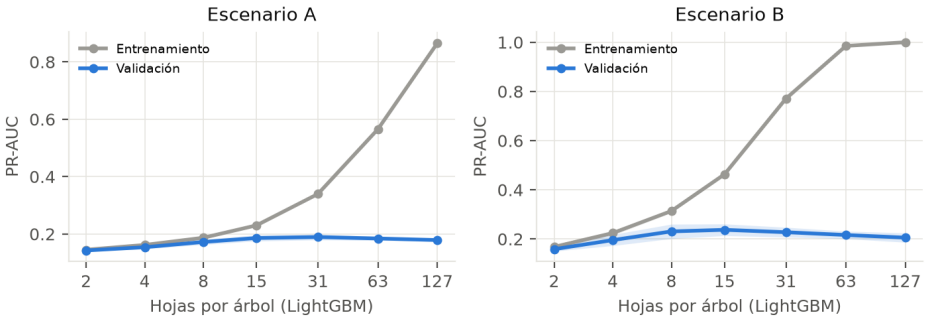


Figura 5: Curva de validación de LightGBM (5 pliegues; banda = ±1 desviación estándar). La brecha entre entrenamiento y validación crece a partir de 15 hojas.

4. Validación, métricas e interpretación preliminar

Métricas. Con 8,8 % de positivos, el F1 ponderado que usa el artículo es engañoso: el clasificador de mayoría obtiene 0,870 en A con el umbral de 0,5, más que cualquier modelo con el umbral calibrado. Por eso usamos (a) el **PR-AUC**, independiente del umbral y cuyo valor de referencia es la prevalencia, para elegir hiperparámetros y comparar modelos; y (b) el **F2** con umbral calibrado, que formaliza la prioridad del *recall* acordada en la Primera entrega (un falso negativo pesa el doble que un falso positivo) sin premiar la solución trivial de alertar a todos, cuyo F2 es 0,325 en A y 0,296 en B. Todas las cifras se reportan con su desviación estándar entre pliegues.

Significancia. Con cinco pliegues, la prueba de Wilcoxon no puede bajar de $p = 0{,}0625$, y la t pareada que usa el artículo subestima la varianza porque los conjuntos de entrenamiento se solapan. Por eso añadimos la t corregida de Nadeau y Bengio (2003). En A, CatBoost nativo supera en PR-AUC a la regresión logística (+0,007; $p_{NB} = 0{,}030$) y a LightGBM con SMOTE (+0,013; $p_{NB} < 0{,}001$), aunque en F2 la ventaja sobre la regresión logística no es significativa ($p_{NB} = 0{,}12$). En B, LightGBM no se distingue ni de CatBoost nativo ($p_{NB} = 0{,}78$) ni de la regresión logística (+0,017; $p_{NB} = 0{,}15$). En síntesis, el *boosting* gana con claridad frente a las líneas base, pero su ventaja sobre un modelo lineal bien regularizado es pequeña y solo es significativa en A. Notamos, de paso, que el artículo interpreta $p = 0{,}003$ como ausencia de diferencia, cuando indica lo contrario.

Punto de operación. Con el umbral F2, el mejor modelo alerta al 45–48 % de los estudiantes para capturar el 70–73 % de los desertores, con una precisión de apenas 0,12–0,14. Es más realista pensar en capacidad fija: si la institución solo puede atender al 20 % de mayor riesgo, captura el 42 % de los desertores en A y el 46 % en B (el azar capturaría el 20 %), es decir, un *lift* de 2,1 a 2,3.

¿Socioeconómicas o desempeño temprano? El análisis de ablación, con LightGBM sin SMOTE, responde la pregunta de investigación (Figura 6). Al ingreso, ningún grupo domina: las variables socioeconómicas (PR-AUC 0,14), las académicas de admisión (0,15) y las institucionales (0,15) aportan cantidades similares, y solo juntas llegan a 0,20. En B, las tres variables del primer periodo solas (0,20) superan a las 28 de ingreso juntas (0,16), y ambas se complementan (0,24). Se reproduce así el hallazgo central del artículo, que el desempeño temprano es el mejor predictor, con un matiz: el contexto socioeconómico añade información que las notas no capturan. Una primera versión de este análisis, hecha con SMOTE, sugería que lo socioeconómico pesaba más que lo académico; esa diferencia desaparece sin el sobremuestreo.

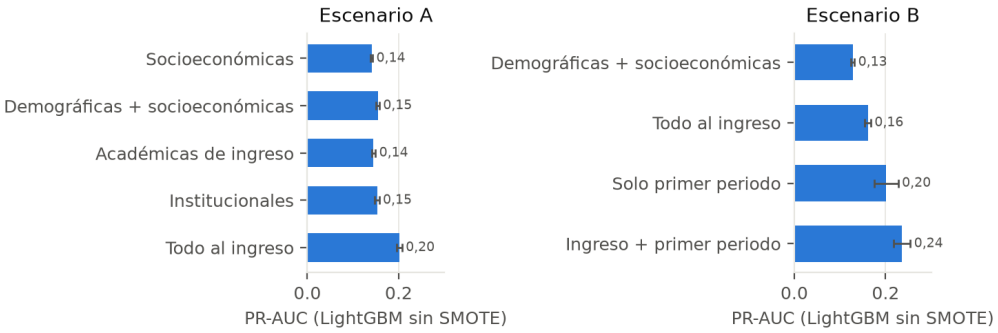


Figura 6: PR-AUC de LightGBM sin SMOTE por grupo de variables (5 pliegues). Al ingreso ningún grupo domina; en B, las tres variables del primer periodo superan al conjunto completo de ingreso.

Variables relevantes y estabilidad. Interpretamos CatBoost nativo en ambos escenarios: es el mejor en A, está empatado con el mejor en B y no usa SMOTE, cuyas muestras sintéticas sobre columnas *one-hot* distorsionan la lectura. SHAP se calculó en cada pliegue externo y se agregó por variable original (Figura 7). En A dominan la nota de matemáticas de admisión, la región del campus, el promedio del bachillerato (`PNA`) y el porcentaje de beca, que en los cinco pliegues nunca salen del top 4. En B, el promedio del primer periodo es la variable más importante en los cinco pliegues, con una contribución media (0,27) del doble que la siguiente (porcentaje de beca, 0,14). La Figura 8 muestra la forma del efecto: el riesgo sube bruscamente solo con promedios bajos (contribuciones de hasta +2,0 en log-odds), mientras que un promedio alto apenas lo reduce. Es un efecto de umbral no lineal, justo el tipo de relación que los árboles capturan mejor que un modelo lineal. Una beca alta, una buena rúbrica de admisión y buenas notas previas reducen el riesgo; tener más edad que la cohorte lo aumenta. Todas estas son asociaciones predictivas, no causales.

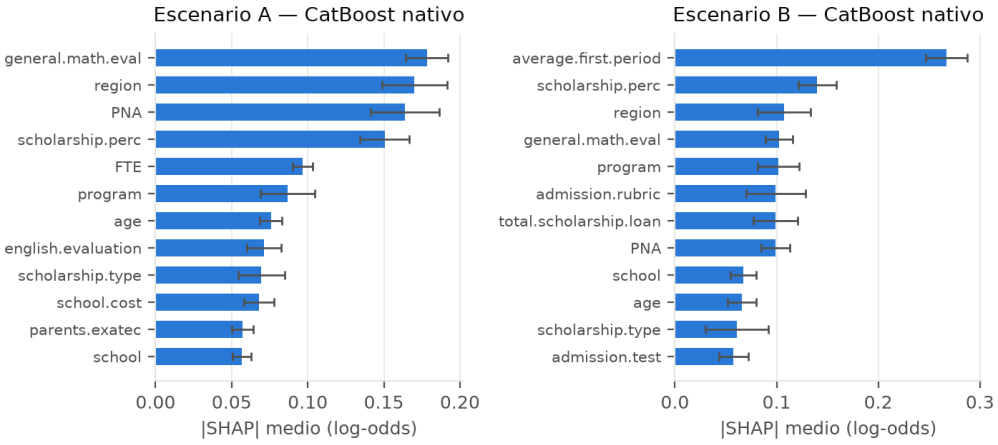


Figura 7: Importancia SHAP media por variable original (CatBoost nativo); las barras de error son la desviación estándar entre los cinco pliegues externos. El desempeño previo y la beca dominan en A; el promedio del primer periodo, en B.

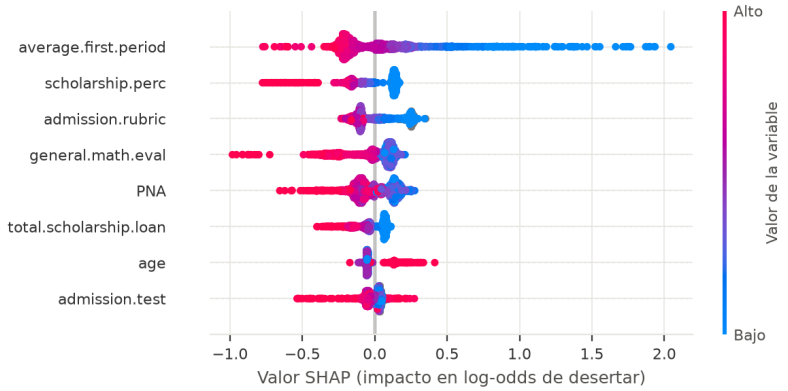


Figura 8: Valores SHAP individuales de las variables numéricas, escenario B (un pliegue de validación). Cada punto es un estudiante; el color indica el valor de la variable.

Errores e implicaciones. El análisis por segmentos (`reports/tables/errores_*.csv`) muestra dónde falla el modelo. Casi no detecta a los desertores con beca de talento académico (*recall* de 0,06–0,11), porque su riesgo base es bajo (4 %) y se van por razones que los datos no registran. En cambio, alerta al 64–65 % de los estudiantes sin beca que no desertan. Para los estudiantes de primera generación el *recall* es alto (0,84–0,88), pero a costa de un 60–64 % de falsas alarmas. En el campus de Monterrey, donde la deserción es menor, el modelo detecta apenas la mitad de los desertores en A. La implicación práctica es que el modelo sirve para *priorizar* el acompañamiento, no para etiquetar estudiantes: varias de sus señales son marcadores socioeconómicos, y usarlo como filtro reforzaría desigualdades existentes.

Pendiente para la Entrega final. Evaluar una sola vez sobre el conjunto de prueba sellado; ampliar las rejillas de los demás ensambles; calibrar las probabilidades; hacer una validación temporal (entrenar con AD14–AD18 y evaluar en AD19–AD20), y desplegar en Streamlit la explicación SHAP individual.

Declaración de uso de IA generativa. Se usó un asistente de IA (Claude, de Anthropic) como apoyo para escribir código y revisar la redacción. El equipo ejecutó, verificó y puede sustentar cada decisión técnica y cada resultado de este informe.

Referencias

[1] Villar, A. & Robledo Velini de Andrade, C. (2024). Supervised machine learning algorithms for predicting student dropout and academic success: a comparative study. *Discover Artificial Intelligence*, 4:2. https://doi.org/10.1007/s44163-023-00079-z

[2] Alvarado-Uribe, J., Mejía-Almada, P., Masetto Herrera, A. L., Molontay, R., Hilliger, I., Hegde, V., Montemayor Gallegos, J. E., Ramírez Díaz, R. A., & Ceballos, H. G. (2022). Student Dataset from Tecnologico de Monterrey in Mexico to Predict Dropout in Higher Education. *Data*, 7(9), 119. https://doi.org/10.3390/data7090119

[3] Martins, M. V., Tolledo, D., Machado, J., Baptista, L. M., & Realinho, V. (2021). Early prediction of student's performance in higher education: a case study. En *Trends and Applications in Information Systems and Technologies*, vol. 9 (pp. 166–175). Springer.

[4] Nadeau, C. & Bengio, Y. (2003). Inference for the generalization error. *Machine Learning*, 52(3), 239–281.

[5] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: synthetic minority oversampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357.

[6] Lundberg, S. M. & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.